

Facultad de Ingeniería - Universidad Nacional de Cuyo			
P1- PROGRAMA DE ASIGNATURA			
Asignatura:	Inteligencia Artificial II		
Profesor Titular:	Dr. Rodrigo Gonzalez		
Carrera:	Licenciatura en Ciencias de la Computación		
Año: 2023	Semestre: 8	Horas Semestre: 90	Horas Semana: 6

### **FUNDAMENTACIÓN**

El Licenciado en Ciencias de la Computación es un graduado universitario con sólida formación básica y una preparación técnica general que le permite comprender, adecuar, desarrollar y aplicar los elementos científicos y las tecnologías vinculadas con la Informática. Es fundamental que el graduado de la carrera entienda tanto aplicar en su desarrollo profesional los diferentes métodos de Inteligencia Artificial que se encuentran en la literatura más reciente, como entender las limitaciones que presentan los mismos.

### **CONTENIDOS MÍNIMOS**

- Planificación básica, diferentes enfoques.
- Planificación avanzada: planificación con recursos y tiempo, planificación y ejecución integradas.
- Razonamiento probabilista en el tiempo.
- Agentes basados en la utilidad.
- Técnicas de búsqueda basadas en meta-heurísticas. Aprendizaje de Maquinas: conceptos, aprendizaje supervisado, no supervisado, por refuerzo. Redes neuronales.

### **OBJETIVOS**

- Reconocer un conjunto avanzado de técnicas simbólicas y sub-simbólicas abarcando los campos más importantes de la Inteligencia Artificial.
- Aplicar análisis, selección de técnicas adecuadas y desarrollo práctico de soluciones para resolver problemas susceptibles de ser atacados con técnicas avanzadas de Inteligencia Artificial.
- Aplicar el método científico como método general para aplicar diferentes técnicas de Inteligencia Artificial a la resolución de problemas concretos.
- Reconocer las limitaciones y alcances de cada uno de los métodos de Inteligencia Artificial vistos durante el cursado.
- Adquirir competencias respecto a la implementación eficiente en software de los diferentes métodos de Inteligencia Artificial vistos durante el cursado.

### **DESGRADADO DE CONTENIDOS**

#### **UNIDAD 1: PLANIFICACIÓN**

##### **1.A. Introducción**

El problema de planificación: definición, representaciones, lenguajes, complejidad. Relación con otros sistemas basados en el conocimiento (unificación, lógica de primer orden, lenguajes de programación lógica). Relación con algoritmos de búsqueda.

##### **1.B. Enfoques de planificación y aplicaciones**

Planificación en el espacio de estados, búsqueda hacia adelante y atrás, heurísticas. Planificación en el espacio de planes, planificación de orden parcial. Técnicas de grafos de planificación. Técnicas de satisfactibilidad proposicional. Planificación por Portfolio.

## **UNIDAD 2: REGRESIÓN LINEAL**

### **2.A. Regresión Lineal Simple.**

Regresión Lineal. Introducción a la Regresión Lineal. Definición y aplicaciones prácticas. Supuestos básicos de la regresión lineal. Estimación de los coeficientes mediante el método de mínimos cuadrados. Interpretación de los coeficientes. Evaluación de la precisión de los coeficientes estimados. Intervalos de confianza. Pruebas de hipótesis. Predicción y intervalos de confianza para las predicciones.

### **2.B. Regresión Lineal Múltiple**

Introducción y diferencias con la regresión lineal simple. Estimación e interpretación de coeficientes. Evaluación de la precisión del modelo. R-cuadrado y R-cuadrado ajustado. Análisis de varianza (ANOVA). T-statistic, P-value. Multicolinealidad y sus soluciones. Selección de variables y criterios (Forward, Backward, Stepwise).

### **2.C. Regresión Logística**

Introducción a la Regresión Logística. Diferencias entre regresión lineal y logística. Aplicaciones y casos de uso. Regresión Logística Binaria. El Modelo Logístico y la función logit. Estimación de los coeficientes de regresión. Interpretación de los coeficientes. Predicción y probabilidades estimadas. Evaluación del modelo: Matriz de confusión, precisión, sensibilidad, especificidad.

### **2.D. Regresión Logística Múltiple**

Introducción y diferencias con la regresión logística binaria. Estimación e interpretación de coeficientes. Evaluación del modelo y selección de variables. Regresión Logística para Respuestas Multiclase. Modelos de regresión logística multinomial y ordinal. Estimación e interpretación de coeficientes. Evaluación del modelo.

### **2.E. Métodos de Regularización**

Introducción a la Regularización. Overfitting y cómo la regularización puede ayudar. Diferencia entre regularización L1 y L2. Ridge Regression (L2). Introducción y aplicaciones. Estimación de coeficientes y lambda óptimo. Lasso Regression (L1). Introducción y aplicaciones. Estimación de coeficientes y lambda óptimo.

## **UNIDAD 3: REDES NEURONALES DE UNA CAPA**

### **3.A. Introducción a las Redes Neuronales**

Historia y evolución de las redes neuronales. Concepto de neurona artificial: inspiración biológica y modelo matemático. Aplicaciones y usos de las redes neuronales de una capa. Componentes Básicos de una Neurona. Entradas y pesos. Función de activación. Umbral (bias) y salida. Funciones de Activación Lineal. Sigmoide. Tanh (tangente hiperbólica). ReLU (Rectified Linear Unit). Ventajas y desventajas de cada función.

### **3.B. Regresión Lineal como una Red Neuronal**

Representación gráfica y matemática. Relación entre regresión lineal y una neurona con función de activación lineal. Entrenamiento y Aprendizaje Concepto de función de pérdida o costo. Método de optimización: descenso del gradiente. Actualización de pesos y sesgos. Tasa de aprendizaje. Regresión Softmax Concepto y aplicación en clasificación multiclase. Cálculo de probabilidades para cada clase. Función de pérdida para la regresión softmax: entropía cruzada. Evaluación de Modelos de Una Capa. Métricas de evaluación: precisión, error cuadrático medio, entropía cruzada. Interpretación de resultados y diagnóstico. Implementación con Keras.

## **UNIDAD 4: REDES CONVOLUCIONALES (CNN)**

### **4.A. Introducción a las Redes Neuronales**

Historia y evolución de las CNN. Aplicaciones prácticas: visión por computadora, procesamiento de imágenes, reconocimiento de patrones. Ventajas de las CNN sobre las redes neuronales tradicionales en el procesamiento de imágenes. Conceptos Básicos de las CNN. Estructura y componentes de una CNN. Operaciones fundamentales: convolución, pooling, y activación.

### **4.B. Operación de Convolución**

Filtros y características. Mapas de características. Padding: valid y same. Striding: impacto en el tamaño del mapa de características. Funciones de Activación en CNN. ReLU y sus variantes: Leaky ReLU, Parametric ReLU, Exponential ReLU. Importancia de las funciones de activación no lineales en las CNN. Pooling y Submuestreo. Pooling máximo y promedio. Beneficios del pooling: reducción de dimensiones y características invariantes. Impacto del tamaño del kernel y striding en el pooling.

### **4.C. Arquitecturas Famosas de CNN**

LeNet-5: Historia, estructura y aplicaciones. AlexNet: Innovaciones y características clave. VGGNet: Profundidad y bloques VGG. Network in Network (NiN): Micro redes y convoluciones 1x1. GoogLeNet e Inception: Módulos Inception y eficiencia computacional. ResNet: Conexiones residuales y solución al problema de degradación. DenseNet: Conexiones densas y conservación de características.

### **4.D. Técnicas Avanzadas en CNN**

Normalización por Lote (Batch Normalization): Beneficios y cómo implementar. Data Augmentation: Técnicas y beneficios para el entrenamiento de CNN. Transfer Learning: Uso de modelos preentrenados y adaptación a nuevas tareas. Implementación con Keras. Creación de modelos CNN con Keras: capas convolucionales, pooling y fully connected.

## **UNIDAD 5: REDES RECURRENTE (RNN)**

### **5.A. Introducción a las Redes Recurrentes**

Historia y evolución de las RNNs. Aplicaciones prácticas: procesamiento de lenguaje natural, series temporales, reconocimiento de voz. Ventajas y desafíos de las RNNs en comparación con las redes feedforward. Conceptos Básicos de las RNNs Estructura y componentes de una RNN. Secuencias y dependencias temporales. Despliegue en el tiempo (unrolling) de una RNN.

### **5.B. Dinámica de las RNNs**

Variables de entrada, ocultas y de salida. Funciones de activación en RNNs. Propagación hacia adelante en RNNs. Problemas en el Entrenamiento de RNNs Desvanecimiento y explosión del gradiente. Soluciones y técnicas para mitigar estos problemas.

### **5.C. Variantes Avanzadas de RNNs**

GRU (Gated Recurrent Units). Estructura y componentes: puertas de actualización y reinicio. Ventajas sobre las RNNs tradicionales. LSTM (Long Short-Term Memory). Estructura y componentes: puertas de entrada, olvido y salida. Celda de memoria. Aplicaciones y ventajas. RNNs Bidireccionales. Concepto y estructura. Aplicaciones y beneficios de capturar dependencias en ambos sentidos.

### **5.D. Modelado de Secuencias con RNNs**

Modelado de series temporales. Generación de texto y secuencias. Modelado de atención y mecanismos de atención en RNNs. Métricas y Evaluación de RNNs. Perplejidad, verosimilitud y entropía. Evaluación de modelos en tareas de clasificación y regresión de secuencias. Implementación con Keras. Creación de modelos RNN con Keras: capas LSTM, GRU y bidireccionales. Preprocesamiento de secuencias: padding y tokenización. Compilación, entrenamiento y evaluación de modelos RNN. Uso de embeddings y capas de

atención en Keras. Técnicas de regularización en RNNs: dropout recurrente.

#### **5.E. Modelos de lenguaje de gran escala**

Evolución y relevancia de los modelos de lenguaje de gran escala (Large Language Models, LLM). Aplicaciones: generación de texto, traducción, resumen, RAG. Arquitecturas y Modelos Destacados Transformer, BERT, GPT (Generative Pre-trained Transformer). Transfer Learning y Fine-Tuning. Uso de modelos preentrenados para tareas específicas. Beneficios y consideraciones. Implementación y Uso de bibliotecas como Hugging Face's Transformers. Ejemplos prácticos y aplicaciones.

### **UNIDAD 6: APRENDIZAJE NO SUPERVISADO Y SISTEMAS DE RECOMENDACIÓN**

#### **6.A. Introducción al Aprendizaje No Supervisado**

Definición y Características. Diferencias entre aprendizaje supervisado y no supervisado. Aplicaciones y casos de uso. Tipos de Aprendizaje No Supervisado. Clustering. Reducción de dimensionalidad. Reglas de asociación.

#### **6.B. Principal Component Analysis (PCA)**

Introducción a PCA. Concepto y objetivos de PCA. Aplicaciones prácticas. Matemáticas detrás de PCA. Descomposición de valores singulares. Cálculo de componentes principales. Implementación y Visualización. Uso de PCA para reducción de dimensionalidad. Visualización de datos en componentes principales.

#### **6.C. K-means Clustering**

Introducción a K-means. Concepto y objetivos de K-means. Algoritmo y pasos de K-means. Elección del Número de Clusters. Método del codo. Evaluación de la cohesión y separación de clusters. Implementación y Visualización. Uso de K-means para agrupación de datos. Visualización de clusters y centroides.

#### **6.D. Reglas de Asociación**

Conceptos Básicos. Soporte, confianza y elevación. Algoritmo Apriori. Aplicaciones Prácticas. Market Basket Analysis. Recomendaciones basadas en reglas de asociación. Implementación. Generación y evaluación de reglas de asociación. Interpretación de resultados.

#### **6.E. Sistemas de Recomendación**

Tipos: basados en contenido, filtrado colaborativo, basados en conocimiento. Aplicaciones prácticas: e-commerce, streaming, publicidad. Filtrado Colaborativo. Basado en memoria: usuarios similares y elementos similares. Basado en modelo: factorización matricial, SVD. Recomendaciones Basadas en Contenido. Perfiles de usuario y perfiles de ítems. Similitud de contenido y recomendación. Sistemas Híbridos y Avanzados. Combinación de técnicas de recomendación. Uso de deep learning en sistemas de recomendación. Evaluación de Sistemas de Recomendación. Métricas: RMSE, precisión, recall, F1-score. Validación cruzada y conjuntos de prueba.

### **METODOLOGÍA DE ENSEÑANZA**

Las clases de teoría se brindan al alumno en formato de video una semana antes de la clase, disponibles en el canal de Youtube de la materia. Durante esa semana, el docente está a disposición de los alumnos para aclarar dudas sobre la teoría. Cada clase es dividida en varios videos. Cada video contiene un tema en particular de la clase de teoría. De esta forma se logra que los videos sean cortos y ágiles. En cada video, un tema de teoría es explicado por el docente con el apoyo de transparencias. En el aula se fomenta un debate sobre los contenidos de la clase teórica para que los alumnos formulen preguntas y compartan sus comentarios. De esta forma se introduce a los alumnos en la clase de teoría dada y se logra que razonen sobre los contenidos brindados.

Las clases de práctica son realizadas junto con los alumnos. Algunos ejercicios de la práctica son asignados a ciertos alumnos una semana antes de la clase. Durante esa semana, el docente está a disposición de los alumnos para aclarar dudas sobre la resolución de los ejercicios. Los mismos son asignados en forma rotativa. El día de la clase de práctica, cada alumno seleccionado expone la resolución del ejercicio asignado. El resto de los alumnos pueden hacer preguntas y compartir sus puntos de vistas. Luego de las exposiciones, se continúa con la resolución del trabajo práctico en el aula con la ayuda del docente. Los ejercicios de la práctica se resuelven en Python y con Keras, framework para deep learning. Para las prácticas se utilizan conjuntos de datos provistos en el sitio Kaggle.com.

Actividad	Carga horaria por semestre
Teoría y resolución de ejercicios simples	30
Formación práctica	
Formación Experimental - Laboratorio	0
Resolución de problemas de de la vida real en informática	40
Actividades de proyecto y diseño	20
<b>Total</b>	<b>90</b>

## **BIBLIOGRAFÍA**

### ***Bibliografía básica***

Autor	Título	Editorial	Año	Ejemplares en biblioteca
Gareth James et at.	An Introduction to Statistical Learning with Python	Springer	2023	
Francois Chollet	Deep Learning with Python, 2nd Edition	Manning Publications Co.	2021	

### ***Bibliografía complementaria***

Autor	Título	Editorial	Año	Ejemplares en biblioteca
Aston Zhang et at.	Dive into Deep Learning	Online book: <a href="https://d2l.ai/">https://d2l.ai/</a>	2023	

## ***EVALUACIONES (S/ Ord. 108-10\_CS)***

### ***Regularización***

Para regularizar la materia se debe:

1. Tener el 75% de asistencia.
2. Participar en clase del 75% de las actividades prácticas.
3. Aprobar los 2 parciales o sus respectivos recuperatorios, con una nota igual o mayor a 6 (seis). Parciales y recuperatorios evalúan contenidos tanto de la teoría como de la práctica.
4. Presentar un anteproyecto de carácter individual antes de la finalización del cursado.

Las fechas fijadas para la toma de los 2 parciales son el 04 de octubre de 2023 y el 15 de noviembre de 2023. Los respectivos recuperatorios se tomarán la semana posterior siguiente a cada parcial, si fuera necesario.

### ***Anteproyecto***

El mismo debe especificar:

1. Título del proyecto final.
2. Objetivos que se pretenden alcanzar.
3. Breve descripción del proyecto a desarrollar con al menos la siguiente información:
4. Descripción del problema a resolver: supervisado, no supervisado, regresión, clasificación.
5. Datos de entrada al modelo.
6. Tipo de algoritmo a implementar.
7. Diagrama en bloques del sistema completo.

### ***Proyecto final***

Luego de regularizar la materia, el alumno continúa con el desarrollo del proyecto final hasta su finalización, estando el docente disponible para consultas durante las horas designadas para tal fin.

Es obligatorio que el alumno entregue por e-mail al Prof. responsable de la cátedra una copia digital del informe del proyecto final al menos 72 horas hábiles antes de presentarse a la mesa.

### ***Aprobación***

Para aprobar la materia, se contemplan dos casos:



En el caso de un **alumno regular**, se debe haber enviado el informe final del proyecto previamente, según se indica en la sección anterior. Adicionalmente, el alumno debe exponer y defender el proyecto final en forma oral exitosamente durante la mesa de examen. Se evalúan el dominio de conceptos y el grado de competencias teórico-prácticas alcanzadas. La aprobación se alcanza con una nota igual o mayor a 6 (seis), que corresponde al 60% respecto de la competencia alcanzada por parte del alumno en los tópicos tratados por la materia.

En el caso de un **alumno libre**, además de las exigencias para un alumno regular, se debe rendir en la mesa un examen escrito teórico-práctico antes de la presentación del proyecto. El mismo puede ser oral o escrito. Aprobado este examen, se procede a la defensa del proyecto final.